

课程笔记

CS224N Lecture 2: Word Vectors and Language Models

整理：AI Course Notes Contributors；授课：Chris Manning

2024 年 4 月

课程版本：2024 年中文讲义整理版

笔记来源：AI Course Notes Contributors

本版处理：移除课件截图和对应图注，不包含 Stanford 原始课件、图片或视频。

授权：笔记依 CC BY-NC-SA 4.0 分享；完整许可与改动记录见下一页。

来源与许可

本中文笔记由 AI Course Notes Contributors 整理，课程版本为 2024；源稿：<https://github.com/hqhq1025/ai-course-notes/tree/717e2df65c3d2eee593c171156a30d4f8f6812b9/cs224n/lecture02>。

笔记内容依 CC BY-NC-SA 4.0 分享：<https://creativecommons.org/licenses/by-nc-sa/4.0/>。

本副本的改动：移除 Stanford 原始课件截图与依赖这些截图的图注，移除课程视频封面/链接，并清理 TeX 源稿中的行尾空白后重新编译为可独立阅读的 PDF；同时加入本来源与许可说明。完整许可文本随本文件夹提供。Stanford 课件、课件图片和视频不包含在该授权内；请从对应年份 Stanford 课程页访问原始课件。

目录

1 优化基础回顾	3
1.1 梯度下降 (Gradient Descent)	3
1.2 随机梯度下降 (SGD)	3
1.3 本章小结	4
2 Word2Vec 回顾与深入	4
2.1 Word2Vec 的核心思想回顾	4
2.2 Word2Vec 参数与计算	4
2.3 Word2Vec 算法族	5
2.4 负采样 (Negative Sampling)	5
2.5 梯度的稀疏性	5
2.6 词向量的“魔力”: 类比关系	6
2.7 本章小结	6
3 基于共现计数的词向量方法	6
3.1 从“预测”到“计数”: 另一种思路	6
3.2 共现矩阵示例	7
3.3 SVD 降维	7
3.4 GloVe: 统一计数与预测的模型	7
3.5 本章小结	8
4 词向量的评估	8
4.1 内在评估与外在评估	8
4.2 内在评估: 类比任务与相似度	8
4.3 外在评估: 命名实体识别	9
4.4 本章小结	9
5 词义与多义性问题	9
5.1 一词多义是常态	9
5.2 Word2Vec 如何处理多义词?	10
5.3 本章小结	10
6 分类与神经网络入门	10
6.1 命名实体识别: 一个分类问题	10
6.2 从线性分类器到神经网络	11
6.3 窗口分类器的神经网络实现	11
6.4 神经元与 logistic 回归的类比	11
6.5 非线性激活函数的必要性	11
6.6 交叉熵损失函数	12
6.7 本章小结	12

7 总结与延伸	12
7.1 讲者的核心总结	12
7.2 全课知识图谱	13
7.3 关键 Takeaways	13
7.4 拓展阅读	13

1 优化基础回顾

本节课承接上一讲的内容，首先回顾梯度下降优化的基本思想，然后深入讨论 Word2Vec 的更多细节，介绍基于计数的词向量方法（共现矩阵与 GloVe），探讨词向量的评估方式和词义消歧问题，最后引入神经网络分类器的基本概念。

1.1 梯度下降 (Gradient Descent)

梯度下降是训练词向量（以及所有神经网络）的核心优化算法。其基本思想是：

1. 我们有一个损失函数 $J(\theta)$ ，希望找到使其最小化的参数 θ
2. 计算 $J(\theta)$ 关于 θ 的梯度 $\nabla_{\theta} J(\theta)$ ，得到“下坡”方向
3. 沿梯度的反方向走一小步，更新参数
4. 重复上述过程

参数更新公式为：

$$\theta^{\text{new}} = \theta^{\text{old}} - \alpha \nabla_{\theta} J(\theta)$$

- θ ：模型的所有参数（对于 Word2Vec，就是所有的词向量）
- α ：学习率（step size），通常是一个很小的数（如 10^{-3} 到 10^{-5} ）
- $\nabla_{\theta} J(\theta)$ ：损失函数关于参数的梯度

学习率不能太大

如果学习率 α 过大，参数更新的步幅过大，可能会“跳过”最小值，甚至导致损失函数发散。因此必须选择足够小的学习率，使参数在每一步都朝着正确的方向微调。

1.2 随机梯度下降 (SGD)

标准梯度下降需要在**整个训练语料**上计算损失函数和梯度，这在数据量很大时极其耗时。实际中，我们使用**随机梯度下降**（Stochastic Gradient Descent, SGD）：

SGD 的核心思想

每次只选取一个小批量（mini-batch，如 16 或 32 个样本）数据，在这个子集上估计梯度，并据此更新参数。虽然每步的梯度估计是**有噪声的**，但：

1. 训练速度大幅提升（不必等待遍历全部数据）
2. 噪声反而有正则化效果，帮助模型跳出局部最优，实际上往往能得到更好的结果

```
1 while True:
2     window = sample_window(corpus)
3     theta_grad = evaluate_gradient(J, window, theta)
4     theta = theta - alpha * theta_grad
```

1.3 本章小结

梯度下降是所有神经网络训练的基础。在实践中，我们几乎总是使用随机梯度下降（SGD）或其变体（如 Adam），因为它不仅比全量梯度下降快得多，而且由于引入的噪声，往往能找到更好的解。参数初始化必须使用**随机小数**（而非全零），否则会因为对称性无法学习。

2 Word2Vec 回顾与深入

2.1 Word2Vec 的核心思想回顾

Word2Vec 的 Skip-gram 模型的核心思想非常简单：

1. 为词表中的每个词随机初始化一个向量
2. 遍历语料中的每个位置，用当前的中心词（center word）预测周围的上下文词（context words）
3. 根据预测误差更新词向量，使其逐渐学会捕捉词与词之间的语义关系

预测概率使用 softmax 函数：

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

- v_c ：中心词 c 的词向量
- u_o ：上下文词 o 的词向量
- V ：整个词表

为什么使用两套词向量？

Word2Vec 为每个词维护两个向量：中心词向量 v 和上下文词向量 u ，这**不是**为了提升性能，而是为了**简化数学推导**。如果只用一套向量，当中心词自身出现在归一化求和中时，会产生一个 x^2 项，使梯度计算变得更复杂。实际上使用一套向量效果略好，但通常的做法是分别训练两套向量，最后取平均。

2.2 Word2Vec 参数与计算

Word2Vec 是一个**词袋模型**（Bag of Words）：它不区分上下文词在左边还是右边，对窗口内所有位置预测相同的概率分布。虽然这看起来是一个很强的简化假设，但仅凭这一点就足以学到非常有用的词向量。

2.3 Word2Vec 算法族

Mikolov 等人 (2013) 的论文中描述了一族算法：

Word2Vec 的两种模型与三种损失函数

模型架构：

1. **Skip-gram (SG)**: 给定中心词，预测上下文词（本课主要介绍的版本）
2. **Continuous Bag of Words (CBOW)**: 给定上下文词，预测中心词

损失函数：

1. Naïve softmax: 简单但计算代价高
2. Hierarchical softmax: 用二叉树加速
3. Negative sampling: 最常用的高效替代方案

2.4 负采样 (Negative Sampling)

Naïve softmax 的分母需要对词表中**所有**词求和，当词表有 40 万词时，这个计算量很大。负采样提供了一种高效的替代方案。

负采样的目标函数为：

$$J_{\text{neg-sample}}(u_o, v_c, U) = -\log \sigma(u_o^T v_c) - \sum_{k \in \{K \text{ sampled}\}} \log \sigma(-u_k^T v_c)$$

- $\sigma(x) = \frac{1}{1+e^{-x}}$: logistic/sigmoid 函数
- 第一项：希望真实上下文词的点积概率**尽量高**
- 第二项：随机采样 K 个“噪声”词，希望它们的点积概率**尽量低**

负样本的采样策略

负样本不是从均匀分布中采样，而是使用**调整过的 unigram 分布**：

$$P(w) = \frac{U(w)^{3/4}}{Z}$$

将词频的 3/4 次方作为采样权重。这个指数使得**低频词被采样的概率相对增加**，介于均匀分布（指数为 0）和按频率采样（指数为 1）之间。实验表明这种“中间”策略效果最好。通常只采样 $K = 5 \sim 10$ 个负样本。

2.5 梯度的稀疏性

使用负采样后，每个窗口只涉及 $2m + 1$ 个窗口词加 $2km$ 个负样本，因此梯度向量**极其稀疏**——绝大多数词的梯度为零。这意味着：

⁰Slides 第 9 页。Word2Vec 可视化，使用 t-SNE 降维展示。

稀疏更新的实现细节

在分布式训练中，梯度的稀疏性非常重要：我们只需更新出现在当前窗口中的少数词向量，而不是整个嵌入矩阵。在实际的深度学习框架中，词嵌入矩阵通常按行存储（而非列），每行对应一个词的向量。

2.6 词向量的“魔力”：类比关系

训练好的词向量展现出令人惊叹的语义属性。最著名的发现是**向量类比**（vector analogies）：

$$\text{king} - \text{man} + \text{woman} \approx \text{queen}$$

这意味着向量空间中的**方向**对应于语义关系：“man $\rightarrow$ king”的方向与“woman $\rightarrow$ queen”的方向近似平行，编码了“统治者”这一语义成分。

Chris Manning 在课堂上演示了多个类比示例：

- **性别类比**：man : king :: woman : **queen**
- **文化知识**：Australia : beer :: Russia : **vodka**
- **工具-动作**：pencil : sketching :: camera : **photographing**
- **政治**：Obama : Clinton :: Reagan : **Nixon**
- **语法**：tall : tallest :: long : **longest**

词向量类比的深层含义

仅仅通过“预测上下文词”这一简单任务，在大量文本上训练，就能自动习得丰富的语义知识——这在词向量刚被发现时几乎被视为“魔法”。虽然现在有了更强大的 ChatGPT 等模型，但词向量所揭示的**分布式语义表示**原理，仍然是现代 NLP 的基石。

2.7 本章小结

Word2Vec 通过极其简单的“预测上下文”任务，在大规模语料上学习到的词向量，能够：（1）将语义相近的词映射到空间中相近的位置；（2）通过向量运算执行语义类比。负采样是实际训练中最常用的高效技巧，它用少量二分类（真实对 vs 噪声对）替代了对整个词表的 softmax 归一化。

3 基于共现计数的词向量方法

3.1 从“预测”到“计数”：另一种思路

Word2Vec 是一种**基于预测**的方法：通过神经网络预测上下文词来学习词向量。但还有一种更直观的思路：既然我们关心的是词与词之间的共现关系，为什么不直接**统计**它们？

构建共现矩阵 X 有两种方式：

- **基于窗口**：类似 Word2Vec，统计每个词在固定窗口内与其他词的共现次数，捕捉**语法和语义**信息
- **基于文档**：统计词在不同文档中的共现，捕捉**主题**信息（即潜在语义分析 LSA 的思路）

3.2 共现矩阵示例

以一个极小的语料为例 (“I like deep learning. I like NLP. I enjoy flying.”)，窗口大小为 1，可以构建出如图所示的共现矩阵。矩阵中的每个元素 X_{ij} 表示词 i 和词 j 在窗口内共现的次数。

共现矩阵的维度问题

共现矩阵的大小为 $|V| \times |V|$ (词表大小的平方)。如果词表有 40 万词，矩阵大小为 $400,000 \times 400,000$ ，远大于 Word2Vec 的 $400,000 \times d$ (d 通常为 100-300)。因此，直接使用共现矩阵作为词向量既存储浪费，又稀疏低效。

3.3 SVD 降维

解决高维问题的经典方法是**奇异值分解** (Singular Value Decomposition, SVD):

$$X = U \Sigma V^T$$

- U 和 V 是正交矩阵 (列向量互相正交且模为 1)
- Σ 是对角矩阵，对角元素 (奇异值) 按大小递减排列

通过只保留最大的 k 个奇异值 (将其余的置零)，我们得到矩阵 X 的最优 k 维近似，从而将高维共现矩阵压缩为低维词向量。

从 LSA 到现代词向量

这种“共现矩阵 + SVD 降维”的方法最早被称为**潜在语义分析** (Latent Semantic Analysis, LSA)，在心理学和信息检索领域有广泛应用。但直接对原始计数做 SVD 效果不佳。Doug Rohde 在 2000 年代的博士论文中发现了一系列改进技巧：对频率取对数、加权窗口距离、使用 Pearson 相关代替原始计数等。他甚至独立发现了线性语义成分的性质，但当时未受到广泛关注。

3.4 GloVe: 统一计数与预测的模型

GloVe (Global Vectors for Word Representation) 由 Stanford 的 Jeffrey Pennington、Richard Socher 和 Chris Manning 于 2014 年提出。它的核心洞察是：

GloVe 的关键直觉：共现概率的比率

单独看一个词与 ice 或 steam 的共现概率，无法提取出有意义的语义成分。但如果看它们的比率：

- $P(\text{solid}|\text{ice})/P(\text{solid}|\text{steam}) \gg 1$ (solid 与 ice 相关)
- $P(\text{gas}|\text{ice})/P(\text{gas}|\text{steam}) \ll 1$ (gas 与 steam 相关)
- $P(\text{water}|\text{ice})/P(\text{water}|\text{steam}) \approx 1$ (water 对两者无偏)

这些比率编码了 ice 与 steam 之间的“固态 vs 气态”语义差异。

⁰Slides 第 21 页。Pennington, Socher, and Manning, EMNLP 2014。

为了将这种比率关系转化为向量空间中的**线性**关系，GloVe 引入了对数：比率的对数变为差值。因此 GloVe 的目标是学习词向量 w_i 和 $\tilde{w}_j$ ，使得：

$$w_i^T \tilde{w}_j + b_i + \tilde{b}_j \approx \log X_{ij}$$

- X_{ij} ：词 i 和词 j 的共现次数
- $b_i, \tilde{b}_j$ ：偏置项

这样，两个词向量的差就对应于它们共现概率比率的对数，从而将语义差异编码为向量空间中的线性关系。

GloVe 与 Word2Vec 的关系

表面上看，Word2Vec 是“基于预测”的方法，GloVe 是“基于计数”的方法。但实际上两者**深度相关**：

- Word2Vec 的 Skip-gram 目标函数可以证明等价于对共现概率矩阵的隐式分解
- GloVe 的优化目标可以看作对共现矩阵的显式分解
- 两者在实践中产生质量相当的词向量

区别更多在于实现细节和训练效率，而非根本原理。

3.5 本章小结

基于共现计数的方法（SVD、LSA、GloVe）提供了学习词向量的另一条路径。GloVe 通过建立共现概率比率与向量差之间的对应关系，将“计数”与“预测”两种方法的优势统一起来。其关键洞察是：共现概率的**比率**（而非绝对值）编码了有意义的语义成分，而**取对数**将比率转化为向量空间中的线性关系。

4 词向量的评估

4.1 内在评估与外在评估

在 NLP 中，评估方法分为两大类：

两类评估方法

- **内在评估** (Intrinsic evaluation)：在特定的子任务上直接评估词向量质量（如类比测试、相似度评分）。优点：快速、帮助理解组件行为。缺点：与最终应用的相关性不确定。
- **外在评估** (Extrinsic evaluation)：将词向量嵌入到真实任务中（如命名实体识别、问答系统），评估任务性能的提升。优点：直接衡量实用价值。缺点：慢、难以隔离词向量本身的贡献。

4.2 内在评估：类比任务与相似度

词向量的内在评估主要有两种方式：

1. **向量类比任务**：形如 “a : b :: c : ?” 的类比题。例如 “man : king :: woman : ?” 应该得到 queen。通过在大量类比题上的正确率来评估词向量质量。

2. **词相似度评分**：让人类标注者给词对打相似度分数 (0-10 分)，然后计算模型给出的余弦相似度与人类评分之间的**相关系数**。

人类相似度判断的数据集

经典的人类相似度评估数据集包括 WordSim-353、SimLex-999 等。例如：

- tiger/tiger: 10.0 (完全相同)
- book/paper: 7.46 (高度相关)
- plane/car: 5.77 (同为交通工具)
- stock/phone: 1.62 (关系较弱)
- stock/jaguar: 0.92 (几乎无关)

好的词向量应该与人类判断高度相关。

4.3 外在评估：命名实体识别

命名实体识别 (Named Entity Recognition, NER) 是一个经典的外在评估任务：识别文本中的人名、地名、组织名等实体。

将 GloVe 词向量加入到 NER 系统中，可以显著提升识别准确率——这说明词向量确实捕捉到了对下游任务有用的语义信息。

4.4 本章小结

评估词向量需要同时关注内在指标（类比正确率、与人类相似度判断的相关性）和外在指标（在下游任务上的性能提升）。内在评估帮助我们理解词向量的质量，外在评估告诉我们它们在实际应用中是否有用。GloVe 和 Word2Vec 在各类评估中表现相当，远优于简单的 SVD 方法。

5 词义与多义性问题

5.1 一词多义是常态

自然语言中的绝大多数词都有**多个含义**。Manning 以 “pike” 为例：

- 一种**武器**（长矛/戟）
- 一种**鱼类**（梭鱼）
- 一种**道路**（收费公路，turnpike 的缩写）
- 一种**跳水姿势**
- 动词：用矛刺
- 澳大利亚俚语：临阵退缩

更常见的多义词如 bank（银行 / 河岸）、star（星星 / 明星）等在日常文本中无处不在。

词义消歧的困难

虽然字典会为每个词列出明确的义项 (sense 1, sense 2, ...), 但实际上词义之间的边界往往是模糊的。例如 “field” 可以指农田、运动场、学术领域、数学中的域等——这些含义之间有程度不等的关联, 硬性划分义项本身就是一种 “人为的简化”。

5.2 Word2Vec 如何处理多义词？

Word2Vec 为每个词只学习一个向量, 不区分不同义项。那么这个唯一的向量代表什么？

词义的叠加 (Superposition)

一个多义词的词向量是其各个义项向量的**加权平均**, 权重为各义项在语料中出现的相对频率:

$$v_{\text{pike}} = f_1 \cdot v_{\text{pike}_1} + f_2 \cdot v_{\text{pike}_2} + \cdots + f_k \cdot v_{\text{pike}_k}$$

其中 f_i 是第 i 个义项的相对频率, v_{pike_i} 是该义项如果单独训练会得到的向量。

这种 “叠加” 看起来会丢失信息——从一个平均向量怎么可能恢复各个义项？但有一个惊人的数学结果：

稀疏编码与义项恢复

由于词向量空间是**高维且稀疏**的, 来自**稀疏编码理论**的方法可以从单个叠加向量中**恢复出各个义项的向量**。Arora 等人 (其中包括 Stanford 的 Tengyu Ma) 在论文中展示了这一技术: 从 “tie” 的单一向量中成功分离出了 “领带”、“比赛平局”、“电线束扎”、“音乐连接符” 等不同义项。

不过在实际应用中, 现代 NLP 更倾向于使用**上下文词向量** (contextual word vectors, 如 BERT、GPT), 它们为每个词在每次出现时生成不同的向量, 从根本上解决了多义性问题。

5.3 本章小结

一词多义是自然语言的基本特征。Word2Vec 等静态词向量将多义词表示为各义项的加权平均, 虽然看似丢失了信息, 但高维空间的稀疏性使得义项在理论上可以被恢复。这一发现为理解词向量的表示能力提供了深刻的数学洞察。后续课程中将介绍的上下文词向量 (如 BERT) 则从根本上解决了多义性问题。

6 分类与神经网络入门

6.1 命名实体识别：一个分类问题

词向量的一个重要应用是作为分类器的输入特征。以**命名实体识别** (NER) 为例: 例如, 判断文本中的 “Paris” 是人名还是地名:

- “Paris Hilton is famous” → Paris 是人名

- “I visited **Paris** last spring” → Paris 是地名

这需要看上下文才能判断。方法是取中心词及其两侧若干词的词向量，拼接成一个长向量，作为分类器的输入。

6.2 从线性分类器到神经网络

传统的统计机器学习分类器（如逻辑回归、SVM、朴素贝叶斯）大多是**线性分类器**：它们学习权重 W ，但输入 x 是固定的，决策边界是线性的。

神经网络分类器的两大优势

1. **学习输入表示**：不仅学习分类权重 W ，还同时学习词的分布式表示（词向量本身也可以被更新），这使得在原始符号空间中，分类器是**非线性的**
2. **非线性决策边界**：通过隐藏层和非线性激活函数，可以表示比线性分类器复杂得多的函数

6.3 窗口分类器的神经网络实现

Manning 展示了一个简单但完整的神经网络分类器：

1. **输入层**：将窗口内 5 个词（如 “museums in Paris are amazing”）的词向量拼接为一个 $5d$ 维向量（若 $d = 100$ ，则为 500 维）
2. **隐藏层**：将拼接向量乘以权重矩阵 W （如 8×500 ），加偏置 b ，通过非线性激活函数（如 sigmoid），得到 8 维隐藏表示
3. **输出层**：将隐藏表示乘以另一个权重向量，通过 sigmoid 函数输出概率（如 “是否为地名”）

6.4 神经元与 logistic 回归的类比

单个人工神经元的数学表达为：

$$h_{w,b}(x) = f(w^T x + b)$$

其中 f 是非线性激活函数（如 sigmoid）：

$$f(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

这和 logistic 回归完全相同。**神经网络的关键在于**：不是只有一个这样的单元，而是有一层这样的单元，它们各自学习不同的权重，提取不同的特征，然后将输出传递给下一层。

6.5 非线性激活函数的必要性

没有非线性，深度毫无意义

如果所有层都是纯线性变换（不加激活函数），那么无论堆叠多少层，整个网络都等价于一个**单层线性变换**： $W_1 W_2 x = W x$ 。只有引入非线性激活函数，每增加一层才真正增加了模型的表达能力，使其能够逼近越来越复杂的函数。

6.6 交叉熵损失函数

在 PyTorch 中训练分类器时，最常用的损失函数是**交叉熵损失**（Cross-Entropy Loss）：

$$H(p, q) = - \sum_c p(c) \log q(c)$$

- p ：真实分布（通常是 one-hot 向量，正确类别为 1，其余为 0）
- q ：模型预测的概率分布

当真实标签是 one-hot 时，交叉熵简化为：

$$H(p, q) = -\log q(\text{correct class})$$

即**负对数似然**（negative log-likelihood）——我们已经很熟悉的损失函数形式。

交叉熵与负对数似然的关系

交叉熵损失和负对数似然在分类任务中是**等价的**。在 PyTorch 中使用 `CrossEntropyLoss` 时，它已经内置了 softmax 和负对数似然的计算，因此模型输出层不需要再手动加 softmax。

6.7 本章小结

神经网络分类器相比传统线性分类器有两个关键优势：（1）可以同时学习输入表示和分类权重，实现端到端的训练；（2）通过非线性激活函数，可以学习任意复杂的决策边界。一个简单的前馈神经网络由输入层、隐藏层和输出层组成，其中隐藏层通过非线性变换将输入重新表示为更适合分类的形式。


7 总结与延伸

7.1 讲者的核心总结

Chris Manning 在本讲中建立了从词向量到神经网络分类器的完整认知链：

1. **优化基础**：梯度下降（特别是 SGD）是训练所有神经网络模型的基础
2. **Word2Vec 深入**：Skip-gram 与 CBOW 两种架构，负采样作为高效训练技巧
3. **计数方法与 GloVe**：共现矩阵 + SVD 降维是另一种学习词向量的路径，GloVe 统一了两种方法
4. **词向量评估**：内在评估（类比、相似度）与外在评估（NER 等下游任务）
5. **词义问题**：多义词向量是各义项的加权叠加，可通过稀疏编码恢复
6. **神经网络入门**：从 logistic 回归到多层网络，非线性激活函数是深度的关键

7.2 全课知识图谱



7.3 关键 Takeaways

五条核心原则

1. **分布式假设是基石**: 词的含义由其上下文决定——无论是 Word2Vec 的预测方法还是 GloVe 的计数方法，都是这一假设的不同实现
2. **向量空间中的方向编码语义**: 词向量不仅捕捉相似性，还通过向量差编码语义关系（类比性质）
3. **预测与计数殊途同归**: Word2Vec 和 GloVe 看似不同，实际上都在对共现统计进行建模
4. **一词多义不是障碍**: 静态词向量通过叠加编码多个义项，上下文词向量则彻底解决了这一问题
5. **非线性是深度学习的灵魂**: 没有非线性激活函数，再多的层也只是线性变换

7.4 拓展阅读

- Mikolov et al., 2013: “Efficient Estimation of Word Representations in Vector Space” — Word2Vec 原始论文
- Mikolov et al., 2013: “Distributed Representations of Words and Phrases and their Compositionality” — 负采样等技巧
- Pennington, Socher, Manning, 2014: “GloVe: Global Vectors for Word Representation” — <https://nlp.stanford.edu/projects/glove/>
- Levy & Goldberg, 2014: “Neural Word Embedding as Implicit Matrix Factorization” — 证明 Word2Vec 与矩阵分解的等价性

- Arora et al., 2018: “Linear Algebraic Structure of Word Senses, with Applications to Polysemy”
—从单一词向量恢复义项
- CS224N 课程主页: <https://web.stanford.edu/class/cs224n/>