

课程笔记

CS224N Lecture 7: Attention and LLM Intro

整理：AI Course Notes Contributors；授课：Chris Manning

2024 年春季

课程版本：2024 年中文讲义整理版

笔记来源：AI Course Notes Contributors

本版处理：移除课件截图和对应图注，不包含 Stanford 原始课件、图片或视频。

授权：笔记依 CC BY-NC-SA 4.0 分享；完整许可与改动记录见下一页。

来源与许可

本中文笔记由 AI Course Notes Contributors 整理，课程版本为 2024；源稿：<https://github.com/hqhq1025/ai-course-notes/tree/717e2df65c3d2eee593c171156a30d4f8f6812b9/cs224n/lecture07>。

笔记内容依 CC BY-NC-SA 4.0 分享：<https://creativecommons.org/licenses/by-nc-sa/4.0/>。

本副本的改动：移除 Stanford 原始课件截图与依赖这些截图的图注，移除课程视频封面/链接，并清理 TeX 源稿中的行尾空白后重新编译为可独立阅读的 PDF；同时加入本来源与许可说明。完整许可文本随本文件夹提供。Stanford 课件、课件图片和视频不包含在该授权内；请从对应年份 Stanford 课程页访问原始课件。

目录

1 机器翻译评估	3
1.1 序列到序列模型回顾	3
1.2 BLEU 评估指标	3
1.3 机器翻译的历史进展	4
1.4 本章小结	4
2 注意力机制	4
2.1 动机：序列到序列的信息瓶颈	4
2.2 注意力机制的工作流程	5
2.2.1 Step 1: 计算注意力分数	5
2.2.2 Step 2: 通过 Softmax 获得注意力分布	5
2.2.3 Step 3: 计算注意力输出	5
2.2.4 Step 4: 拼接并生成输出词	5
2.2.5 重复：逐步翻译	5
2.3 本章小结	5
3 注意力的数学形式化	6
3.1 Dot-Product Attention 的数学表示	6
3.2 注意力变体	6
3.2.1 基本点积注意力 (Basic Dot-Product Attention)	7
3.2.2 乘法注意力 / 双线性注意力 (Multiplicative / Bilinear Attention)	7
3.2.3 降秩乘法注意力 (Reduced-Rank Multiplicative Attention)	7
3.2.4 加法注意力 (Additive Attention)	7
3.3 本章小结	8
4 注意力的优势与通用性	8
4.1 注意力带来的四大优势	8
4.1.1 显著提升 NMT 性能	8
4.1.2 更接近人类的翻译过程	9
4.1.3 解决信息瓶颈	9
4.1.4 缓解梯度消失问题	9
4.2 注意力提供可解释性	9
4.3 注意力是通用技术	9
4.4 关于 RNN 注意力中的位置信息	10
4.5 本章小结	10
5 从注意力到 Transformer 与大语言模型	10
5.1 注意力的历史演进	10
5.2 从编码器-解码器注意力到自注意力	11
5.3 大语言模型简介	11
5.4 本章小结	12

6 NLP 实验实践建议	12
6.1 研究项目的基本要素	12
6.2 基线的重要性	12
6.3 计算资源的策略	13
6.4 本章小结	13
7 总结与延伸	13
7.1 讲者的核心总结	13
7.2 全课知识图谱	14
7.3 关键 Takeaways	14
7.4 拓展阅读	14

1 机器翻译评估

本讲的第一部分承接上一讲的序列到序列 (Sequence-to-Sequence) 机器翻译模型，讨论如何评估机器翻译系统的质量。

1.1 序列到序列模型回顾

在上一讲中，我们介绍了基于多层 LSTM 的编码器-解码器 (Encoder-Decoder) 架构用于机器翻译。编码器读入源语言句子，将信息压缩到最后一个隐藏状态中；解码器以此为初始状态，逐词生成目标语言翻译。

信息瓶颈问题

在标准的 Seq2Seq 架构中，源句的**所有信息**必须被压缩到编码器最后一个隐藏状态向量中。对于短句子这或许可以接受，但当源句长达 40 个词时，将全部语义信息塞入一个固定大小的向量显然是不合理的。这个问题被称为**信息瓶颈 (Information Bottleneck)**，也是注意力机制被发明的直接动因。

1.2 BLEU 评估指标

为了自动评估机器翻译质量，Papineni 等人 (2002) 提出了 **BLEU (Bilingual Evaluation Understudy)** 指标。在此之前，翻译质量只能通过人工评估来衡量，这虽然是金标准，但成本高昂且无法嵌入训练循环。

BLEU 指标的核心思想

BLEU 通过计算机器翻译与人工参考翻译之间的 **n-gram 重叠度** 来衡量翻译质量：

- 计算 1-gram、2-gram、3-gram、4-gram 的精确率 (precision)
- 取这些精确率的**几何平均值**
- 加入**简短惩罚 (brevity penalty)**，防止系统通过只翻译简单部分来获取高分

BLEU 分数理论上在 0-100 之间，但由于翻译的多样性，永远不会达到 100。

BLEU 分数的解读

- **20 分左右**：可以大致理解源文档的主题
- **30-40 分**：翻译质量开始变得不错
- **50-60 分**：现代神经机器翻译系统在一些语言对上已达到的水平

原始设计建议使用多个参考翻译来更好地覆盖翻译空间，但实践中使用单个参考翻译也很常见。

⁰Slides 第 3 页。参考 Sutskever et al. 2014; Luong et al. 2015。

⁰Slides 第 4 页。来源：Papineni et al., 2002。

BLEU 的局限性

BLEU 是一个有用但不完美的指标：

- 一个好的翻译可能因为措辞与参考翻译不同而获得低分
- 一个差的翻译可能因为碰巧包含一些正确的词而获得一些分数
- 它无法捕捉语义等价性——同义词替换会被错误惩罚

因此，人工评估在高风险场景中仍然是必不可少的。

1.3 机器翻译的历史进展

机器翻译技术经历了三个重要阶段：

1. **统计短语翻译** (Phrase-based SMT, 1990s–2010s): IBM 开创，Google Translate 最初使用此方法。进展缓慢，BLEU 分数几乎停滞。
2. **句法翻译** (Syntax-based SMT, 2005–2015): 试图利用句法结构改善翻译，尤其针对词序差异大的语言对（如德-英、中-英），但改进幅度有限。
3. **神经机器翻译** (Neural MT, 2014 至今): 2014 年首次出现，2015 年在 bake-off 评测中亮相，2016 年超越所有传统方法，此后一路高歌猛进。

NMT 的崛起

Manning 教授指出，在 2005–2014 年间，机器翻译社区的主流观点是“要想做好翻译，必须理解句法结构”。然而，神经机器翻译的成功表明，端到端学习可以隐式地捕获这些结构信息，这彻底颠覆了传统思维。注意力机制是推动 NMT 成功的关键技术之一。

1.4 本章小结

- BLEU 是最广泛使用的机器翻译自动评估指标，基于 n-gram 精确率的几何平均
- BLEU 有用但不完美，好翻译可能低分，差翻译可能得分
- 神经机器翻译从 2014 年起迅速超越传统方法，注意力机制是其成功的核心要素
- 编码器-解码器架构存在信息瓶颈，这直接催生了注意力机制的发明

2 注意力机制

注意力 (Attention) 是近年来神经网络领域最重要的创新之一。Manning 教授强调，前面课程中介绍的所有技术（前馈网络、RNN、LSTM、CNN）都是上世纪发明的，而注意力是 2014 年在神经机器翻译背景下**全新发明**的概念，它对提升神经网络的能力具有变革性意义。

2.1 动机：序列到序列的信息瓶颈

标准 Seq2Seq 模型的核心问题在于：

- 编码器将整个源句压缩为**单一向量**
- 对于长句子，这个向量无法承载所有必要信息
- 粗暴的解决方案（增大隐藏状态、增加层数）效果有限
- 人类翻译时会**回头查看**源句的不同部分，而不是一次性记住所有内容

注意力的核心思想

在解码器的**每一步**，建立与编码器的**直接连接**，让解码器能够**聚焦**于源序列的特定部分，从而按需获取信息。这就像人类翻译时回头查看原文的特定词语一样。

2.2 注意力机制的工作流程

注意力机制在 Seq2Seq 中的完整工作流程可以分解为以下步骤：

2.2.1 Step 1: 计算注意力分数

在解码器的每个时间步 t ，用解码器当前隐藏状态 s_t 与编码器每个位置的隐藏状态 h_i 计算注意力分数（最简单的方式是点积）。

2.2.2 Step 2: 通过 Softmax 获得注意力分布

将注意力分数通过 softmax 转换为概率分布，表示解码器在当前时间步应该“关注”源句哪些位置。

2.2.3 Step 3: 计算注意力输出

用注意力分布对编码器隐藏状态做**加权求和**，得到注意力输出（attention output），也称为上下文向量（context vector）。

2.2.4 Step 4: 拼接并生成输出词

将注意力输出与解码器隐藏状态**拼接**（concatenate），送入后续层生成下一个词。

2.2.5 重复：逐步翻译

在后续每个解码步骤中，重复上述过程。每一步解码器都会重新计算注意力，关注源句的不同部分。

2.3 本章小结

注意力机制的工作流程可以总结为四步：

1. **计算注意力分数**：解码器隐藏状态与编码器各位置隐藏状态的相似度
2. **Softmax**：将分数转换为概率分布
3. **加权求和**：用注意力分布对编码器隐藏状态求加权平均，得到上下文向量
4. **拼接与生成**：将上下文向量与解码器隐藏状态拼接，生成输出词

3 注意力的数学形式化

3.1 Dot-Product Attention 的数学表示

设编码器隐藏状态为 $\mathbf{h}_1, \dots, \mathbf{h}_N \in \mathbb{R}^h$ ，解码器在时间步 t 的隐藏状态为 $\mathbf{s}_t \in \mathbb{R}^h$ 。注意力计算的完整公式如下：

第一步：计算注意力分数

$$\mathbf{e}^t = [\mathbf{s}_t^T \mathbf{h}_1, \dots, \mathbf{s}_t^T \mathbf{h}_N] \in \mathbb{R}^N$$

- $\mathbf{e}^t$ ：时间步 t 的注意力分数向量
- $\mathbf{s}_t^T \mathbf{h}_i$ ：解码器状态与编码器第 i 个位置状态的点积

第二步：通过 Softmax 得到注意力分布

$$\boldsymbol{\alpha}^t = \text{softmax}(\mathbf{e}^t) \in \mathbb{R}^N$$

- $\boldsymbol{\alpha}^t$ 是一个概率分布，所有元素非负且和为 1

第三步：计算注意力输出（上下文向量）

$$\mathbf{a}_t = \sum_{i=1}^N \alpha_i^t \mathbf{h}_i \in \mathbb{R}^h$$

- $\mathbf{a}_t$ ：编码器隐藏状态的加权平均，权重由注意力分布决定

第四步：拼接并生成

$$[\mathbf{a}_t; \mathbf{s}_t] \in \mathbb{R}^{2h}$$

将注意力输出与解码器隐藏状态拼接，得到双倍长度的向量，通过线性变换和 softmax 生成输出词的概率分布。

注意力机制的本质

注意力机制本质上是一种**软性信息检索**：给定一个查询（query，即解码器状态），在一组值（values，即编码器状态）中寻找最相关的信息，并通过加权平均的方式提取出来。这种“查询-键值”的思想后来在 Transformer 中被进一步发展为 Query-Key-Value 框架。

3.2 注意力变体

注意力机制的通用框架包含一组值（values） $\mathbf{h}_1, \dots, \mathbf{h}_N \in \mathbb{R}^{d_1}$ 和一个查询（query） $\mathbf{s} \in \mathbb{R}^{d_2}$ 。不同的注意力变体在“如何计算注意力分数”这一步有所不同。

3.2.1 基本点积注意力 (Basic Dot-Product Attention)

$$e_i = \mathbf{s}^T \mathbf{h}_i \in \mathbb{R}$$

- 最简单的形式，直接计算查询和值的点积
- 要求 $d_1 = d_2$ (查询和值的维度必须相同)
- 优点：计算高效，无需额外参数
- 缺点：隐藏状态必须同时存储多种信息 (输出当前词、记录语法结构、规划未来)，并非所有维度都与“回头查看”相关

3.2.2 乘法注意力 / 双线性注意力 (Multiplicative / Bilinear Attention)

$$e_i = \mathbf{s}^T \mathbf{W} \mathbf{h}_i \in \mathbb{R}$$

其中 $\mathbf{W} \in \mathbb{R}^{d_2 \times d_1}$ 是可学习的权重矩阵。

为什么乘法注意力更好

Manning 教授解释道：LSTM 的隐藏状态是它的“完整记忆”，需要存储多种不同类型的信息。编码器和解码器可能将相同类型的信息存储在不同的维度上。乘法注意力通过可学习的矩阵 $\mathbf{W}$ ，能够学习到“解码器的哪些维度应该与编码器的哪些维度匹配”，而不要求维度对维度的精确对应。这是 Luong, Pham 和 Manning 在 2015 年提出的方法。

3.2.3 降秩乘法注意力 (Reduced-Rank Multiplicative Attention)

乘法注意力的一个问题是矩阵 $\mathbf{W}$ 的参数量为 $d_1 \times d_2$ (如果隐藏状态维度为 1000，则有 100 万个参数)。解决办法是将 $\mathbf{W}$ 分解为两个低秩矩阵：

$$e_i = \mathbf{s}^T (\mathbf{U}^T \mathbf{V}) \mathbf{h}_i = (\mathbf{U} \mathbf{s})^T (\mathbf{V} \mathbf{h}_i)$$

其中 $\mathbf{U} \in \mathbb{R}^{k \times d_2}$, $\mathbf{V} \in \mathbb{R}^{k \times d_1}$, $k \ll d_1, d_2$ 。

从降秩注意力到 Transformer

降秩乘法注意力的本质是：先将查询和值投影到低维空间，再在低维空间中做点积。这正是 Transformer 中多头注意力的做法！Transformer 取每个大向量，通过投影矩阵将其映射到低维空间，然后在低维空间中计算点积注意力。理解这一点是理解 Transformer 的关键。

3.2.4 加法注意力 (Additive Attention)

$$e_i = \mathbf{v}^T \tanh(\mathbf{W}_1 \mathbf{h}_i + \mathbf{W}_2 \mathbf{s}) \in \mathbb{R}$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{d_3 \times d_1}$, $\mathbf{W}_2 \in \mathbb{R}^{d_3 \times d_2}$, $\mathbf{v} \in \mathbb{R}^{d_3}$, d_3 是注意力维度 (超参数)。

⁰Slides 第 25 页。参考 Luong, Pham, and Manning 2015。

加法注意力的历史地位

加法注意力是 Bahdanau, Cho, and Bengio (2014) 提出的**最早的注意力形式**。它本质上是一个小型前馈神经网络，用于计算注意力分数。虽然后续研究表明，经过良好的超参数调优后加法注意力可能优于乘法注意力，但由于乘法注意力**更简单、更高效**，在实践中（特别是 Transformer 中）乘法注意力几乎完全胜出。

注意力类型	公式	额外参数	提出者
基本点积	$\mathbf{s}^T \mathbf{h}_i$	无	—
乘法/双线性	$\mathbf{s}^T \mathbf{W} \mathbf{h}_i$	$\mathbf{W}$	Luong et al. 2015
降秩乘法	$(\mathbf{U} \mathbf{s})^T (\mathbf{V} \mathbf{h}_i)$	$\mathbf{U}, \mathbf{V}$	(Transformer 使用)
加法	$\mathbf{v}^T \tanh(\mathbf{W}_1 \mathbf{h}_i + \mathbf{W}_2 \mathbf{s})$	$\mathbf{W}_1, \mathbf{W}_2, \mathbf{v}$	Bahdanau et al. 2014

表 1: 四种注意力变体对比

3.3 本章小结

- 注意力机制可以用四个步骤的数学公式完整描述
- 核心差异在于如何计算注意力分数：点积、乘法、降秩乘法、加法
- 降秩乘法注意力通过低维投影 + 点积实现，这正是 Transformer 的做法
- 实践中，乘法/降秩注意力因高效而成为主流

4 注意力的优势与通用性

4.1 注意力带来的四大优势

4.1.1 显著提升 NMT 性能

注意力机制的引入对神经机器翻译性能有**变革性**提升。Manning 教授讲述了一个重要历史：

- **2014 年**，Google (Sutskever 等) 使用纯 LSTM (8 层深，非常大的隐藏状态) 进行机器翻译，需要巨大的计算资源
- 同年，蒙特利尔大学的 Bahdanau, Cho, Bengio 引入注意力机制，以**远小**的计算预算获得了**更好**的结果
- 此后，**所有**新的机器翻译系统都使用了注意力机制

注意力是 NMT 的秘密武器

Bahdanau 等人在蒙特利尔大学以远低于 Google 的计算预算，通过引入注意力机制获得了更好的翻译结果。注意力不仅是一种优化，更是一种根本性的架构改进，它使得网络能够更有效地利用已编码的信息。

4.1.2 更接近人类的翻译过程

人类翻译时不会先把整个句子“记住”再翻译，而是会在翻译每个词或短语时**回头查看**源句的对应部分。注意力机制模拟了这种行为：解码器在每个时间步都可以“回看”编码器的不同位置。

4.1.3 解决信息瓶颈

有了注意力，解码器不再需要仅依赖编码器最后一个隐藏状态。它可以直接访问编码器在每个位置的隐藏状态，从而利用**整个**编码表示空间。

4.1.4 缓解梯度消失问题

注意力机制在编码器隐藏状态和解码器之间建立了**直接的快捷连接** (shortcut connections)。这与残差连接的思想相同：通过跳过中间的长链依赖，梯度可以更容易地反向传播到编码器的早期位置。

4.2 注意力提供可解释性

注意力机制的一个额外好处是提供了一定程度的**可解释性**。通过查看注意力分布，我们可以观察到模型在翻译每个词时“关注”的是源句的哪个位置，从而获得一种**软对齐** (soft alignment)。

免费获得的对齐信息

传统机器翻译中，词对齐 (word alignment) 是需要单独训练的组件。而注意力机制在翻译过程中**自动学会了对齐**，无需任何显式的对齐监督。Manning 教授称这是“cool”的——网络自己发现了源语言和目标语言词汇之间的对应关系。例如在法译英中，翻译“he”时关注“il”，翻译“me”时关注“m”，翻译“pie”时关注“entarté”。

注意力可解释性的局限

虽然注意力权重提供了有价值的直觉，但将其直接解读为“模型在关注什么”需要谨慎。后续研究表明：

- 注意力权重并不总是与特征重要性一致
- 不同的注意力分布有时会产生相似的输出
- 多层 Transformer 中的注意力模式更加复杂，简单的可视化可能产生误导

因此，注意力权重只能作为一种**近似的**可解释性工具，而非确定性的因果解释。

4.3 注意力是通用技术

Manning 教授强调，注意力不仅仅适用于机器翻译。它是一种**通用技术** (general technique)，可以应用于任何需要从一组值中选择性提取信息的场景：

- 给定一组**值** (values) 和一个**查询** (query)
- 通过注意力计算值的加权平均
- 从中提取与查询最相关的信息

注意力的通用公式

给定值 $\mathbf{h}_1, \dots, \mathbf{h}_N \in \mathbb{R}^{d_1}$ 和查询 $\mathbf{s} \in \mathbb{R}^{d_2}$:

1. 计算注意力分数: $\mathbf{e} \in \mathbb{R}^N$
2. 计算注意力分布: $\boldsymbol{\alpha} = \text{softmax}(\mathbf{e}) \in \mathbb{R}^N$
3. 计算注意力输出: $\mathbf{a} = \sum_{i=1}^N \alpha_i \mathbf{h}_i \in \mathbb{R}^{d_1}$

这个框架在各种神经网络架构中都被证明能**一致地提升性能**。而这一通用框架最重要的应用就是 Transformer 中的**自注意力** (self-attention)，将在下一讲详细介绍。

4.4 关于 RNN 注意力中的位置信息

在课堂问答中，有同学问到 RNN 注意力是否需要位置编码。Manning 教授解释：

为什么 RNN 注意力不需要位置编码

在基于 RNN 的注意力中，编码器的隐藏状态是通过递归计算得到的，每个位置的表示都依赖于前面所有位置。因此，位置信息已经**隐式编码**在隐藏状态中——第 3 个位置的隐藏状态“知道”它处于句子的第 3 个位置，因为它已经处理了前两个词。

而 Transformer 必须使用**显式的位置编码**，正是因为它没有递归结构，所有位置是并行处理的，没有天然的顺序信息。

4.5 本章小结

- 注意力带来四大优势：提升性能、更人类化、解决瓶颈、缓解梯度消失
- 注意力自动学会软对齐，提供可解释性（但需谨慎解读）
- 注意力是通用技术，适用于任何“从值集合中按需提取信息”的场景
- RNN 注意力不需要位置编码（信息已隐含在递归计算中），但 Transformer 需要
- 注意力的下一个重大飞跃是**自注意力**——Transformer 的核心

5 从注意力到 Transformer 与大语言模型

5.1 注意力的历史演进

注意力机制从 2014 年的发明到成为现代 AI 的基石，经历了快速而深远的发展：

年份	里程碑	关键人物
2014	加法注意力 (NMT)	Bahdanau, Cho, Bengio
2015	乘法/双线性注意力	Luong, Pham, Manning
2017	Transformer (自注意力)	Vaswani et al.
2018	BERT (双向 Transformer)	Devlin et al.
2018–今	GPT 系列 (大语言模型)	OpenAI


表 2: 注意力机制的发展时间线

注意力是深度学习新时代的开端

Manning 教授指出，此前神经网络的所有核心组件（前馈网络、RNN、LSTM、CNN）都是在 2000 年之前发明的，深度学习革命的前半段主要是“等待数据和算力赶上”。而注意力是 2014 年之后真正的新发明，它开启了 Transformer、BERT、GPT 等一系列变革性工作。

5.2 从编码器-解码器注意力到自注意力

在 Seq2Seq 中，注意力用于解码器“回头查看”编码器。而 Transformer 的核心创新是**自注意力** (Self-Attention) ——让序列中的每个位置都可以关注同一序列中的所有其他位置。



Manning 教授预告，下一讲 (Lecture 8) 将详细介绍 Transformer 架构，包括自注意力、多头注意力、位置编码等核心概念。

5.3 大语言模型简介

课程后半段还涉及了大语言模型 (LLM) 时代对 NLP 研究和实践的影响：

- **BERT**：基于 Transformer 编码器的双向预训练模型，通过微调适应各种下游任务

- **GPT 系列**：基于 Transformer 解码器的自回归语言模型，展现出强大的零样本和少样本学习能力
- **上下文学习 (In-Context Learning)**：大模型可以通过提示 (prompt) 中的少量示例学习新任务，无需更新参数

LLM 时代的研究范式转变

Manning 教授提到，LLM 的出现改变了研究方式：许多项目不再需要从头训练模型，而是通过 API 调用大语言模型、进行上下文学习或微调来完成任务。这使得更多研究精力可以投入到理解模型行为、评估能力边界、探索新的交互范式等方面。同时，较小的开源模型（如 7B 参数级别）也为预算有限的研究者提供了可能。

5.4 本章小结

- 注意力机制从 2014 年的 NMT 应用发展到 2017 年的 Transformer，再到当今的大语言模型
- 自注意力是 Transformer 的核心，允许序列内部各位置相互交互
- 降秩乘法注意力直接对应 Transformer 的多头注意力设计
- 大语言模型建立在多层 Transformer 之上，通过预训练获得通用能力

6 NLP 实验实践建议

课程的后半部分，Manning 教授给出了关于 NLP 研究和实验的实用建议。

6.1 研究项目的基本要素

好的 NLP 研究项目的关键要素

1. **明确的数据来源**：在项目开始前就确定使用什么数据
2. **清晰的评估方法**：定义如何衡量系统性能
3. **合适的基线 (Baseline)**：必须有一个对比对象来证明你的方法有价值
4. **实质性的价值贡献**：不能只是下载一个好模型跑一下数据——需要有分析、理解、改进

6.2 基线的重要性

Manning 教授强调，任何研究都需要一个合适的基线：

- 如果之前有人做过相同任务，使用他们的结果作为基线
- 如果是全新任务，设计一个简单直觉的方法作为基线（例如：用词向量平均值的余弦相似度做文本相似度）
- 你的复杂模型必须**显著优于**这个简单基线，否则不具说服力

没有基线的研究是不完整的

仅仅展示“我的模型达到了某个数字”是不够的。没有对比，读者无法判断这个数字是好还是坏。Manning 教授举例：如果你构建了一个复杂的神经网络来计算文本相似度，但它的表现还不如简单地将词向量取平均后做点积，那么这个系统就不是一个好系统。

6.3 计算资源的策略

在 GPU 资源日益紧张的今天（Manning 教授戏称“这都怪 OpenAI”），合理利用计算资源至关重要：

- **云端 Notebook**：Google Colab、Kaggle Notebooks、AWS SageMaker Studio Lab 提供免费 GPU
- **低成本 GPU 提供商**：Modal、Vast.ai 等
- **API 访问**：对于 LLM 项目，API 调用（如 Together AI）可能比自己训练更高效
- **选择合适的模型大小**：7B 参数模型的 API 成本远低于 70B 模型，在许多任务上已经够用

模型大小的权衡

Manning 教授建议：在做实验之前，先考虑你**真正需要**多大的模型。如果 7B 参数模型足以证明你的观点，就不必使用更大的模型。50 美元的 API 额度在 7B 模型上可以处理海量 token，但在大模型上可能很快用完。研究的关键不在于使用最大的模型，而在于**证明有趣的结论**。

6.4 本章小结

- 好的研究需要明确的数据、评估方法和基线
- 基线是不可或缺的——没有对比就没有说服力
- 合理选择模型大小和计算策略，可以在有限预算下完成高质量研究
- 批判性思维是研究的核心能力：理解方法的优缺点，而非简单复述


7 总结与延伸

7.1 讲者的核心总结

Chris Manning 在本讲中构建了从机器翻译评估到注意力机制的完整知识链：

1. **评估是基础**：BLEU 虽不完美，但为自动化评估机器翻译提供了可能，是推动 NMT 发展的重要工具
2. **瓶颈催生创新**：Seq2Seq 的信息瓶颈直接促使了注意力机制的发明
3. **注意力是变革性创新**：2014 年发明的注意力机制是自 LSTM 以来神经网络最重要的新概念
4. **理解变体为理解 Transformer 做准备**：特别是降秩乘法注意力直接对应 Transformer 的设计

7.2 全课知识图谱



7.3 关键 Takeaways

五条核心原则

1. **信息瓶颈催生注意力**：将整个句子压缩为单一向量是有根本缺陷的，注意力通过直接连接解决了这一问题
2. **注意力 = 软性信息检索**：给定查询，在值集合中找到最相关的信息并通过加权平均提取
3. **降秩投影是关键**：将高维空间投影到低维再做点积，既减少参数又提高灵活性——这就是 Transformer 的做法
4. **注意力是通用技术**：不仅限于机器翻译，适用于任何需要选择性信息提取的场景
5. **注意力开启了新时代**：从 2014 年的发明到 Transformer 再到 GPT/BERT，注意力机制是过去十年 AI 领域最具影响力的技术创新

7.4 拓展阅读

- Bahdanau, Cho, Bengio, “Neural Machine Translation by Jointly Learning to Align and Translate”, 2014. <https://arxiv.org/abs/1409.0473> ——注意力机制的开山之作
- Luong, Pham, Manning, “Effective Approaches to Attention-based Neural Machine Translation”, 2015. <https://arxiv.org/abs/1508.04025> ——乘法注意力、多种注意力变体对比
- Vaswani et al., “Attention Is All You Need”, 2017. <https://arxiv.org/abs/1706.03762> ——Transformer 原始论文
- Papineni et al., “BLEU: a Method for Automatic Evaluation of Machine Translation”, 2002. <https://aclweb.org/anthology/P02-1040> ——BLEU 指标原始论文
- Ruder, “Deep Learning for NLP Best Practices”, 2017. <http://ruder.io/deep-learning-nlp-best-practices/index.html#attention> ——深度学习 NLP 最佳实践

- Britz et al., “Massive Exploration of Neural Machine Translation Architectures”, 2017. <https://arxiv.org/abs/1703.03906> ——NMT 架构大规模实验
- Sutskever, Vinyals, Le, “Sequence to Sequence Learning with Neural Networks”, 2014. <https://arxiv.org/abs/1409.3215> ——Seq2Seq 原始论文